Autor: Stanislav Burtsaev

Projektdokumentation

Wann fragen statt antworten? Eine Untersuchung des Klärungsverhaltens von LLMs bei unterbestimmten Nutzeranfragen

Kurzfassung

In diesem Projekt wurde untersucht, ob Large Language Models erkennen können, wann eine Nutzeranfrage zu wenig Information enthält und deshalb eine Klärungsfrage notwendig ist. Dafür wurden zwei lokal ausgeführte Modelle (Gemma 4 12B und Qwen 3.8 27B) unter drei verschiedenen Prompt-Bedingungen getestet: ohne eigenen System-Prompt, mit einem allgemeinen Helpful-Assistant-Prompt und mit einem speziell formulierten Klärungs-Prompt. Der Datensatz bestand aus 50 kontrollierten Minimalpaaren, also insgesamt 100 Anfragen. Jede unvollständige Anfrage hatte eine möglichst ähnliche, vollständig spezifizierte Gegenvariante. Insgesamt entstanden 600 Modellantworten. Die Ergebnisse zeigen, dass der spezielle Klärungs-Prompt die Erkennung notwendiger Rückfragen deutlich verbessert, ohne in unserem Datensatz zu mehr unnötigen Rückfragen bei bereits klaren Anfragen zu führen. Besonders auffällig ist jedoch, dass beide Modelle lexikalische Mehrdeutigkeit wesentlich schlechter erkennen als strukturell fehlende Informationen.

1. Ausgangsidee und Ziel des Projekts

Ausgangspunkt des Projekts war die Frage, wie Sprachmodelle mit Unsicherheit auf der Eingabeseite umgehen. Viele Fehler entstehen nicht deshalb, weil ein Modell eine Tatsache nicht kennt, sondern weil eine Anfrage mehrere plausible Interpretationen zulässt oder wichtige Angaben fehlen. Ein hilfreicher Assistent sollte in solchen Situationen nicht einfach eine wahrscheinlich wirkende Interpretation auswählen, sondern zunächst nachfragen.

Das Projekt knüpft damit direkt an den Seminarbereich zur Unsicherheitskommunikation und zu Klärungsfragen an. Im Mittelpunkt steht nicht die interne Wahrscheinlichkeit eines Modells und auch nicht eine Selbstauskunft wie „Ich bin zu 80 % sicher“. Stattdessen wird beobachtbares Verhalten untersucht: Antwortet das Modell direkt, oder erkennt es, dass eine Rückfrage notwendig ist?

Das Ziel war deshalb, ein kleines, reproduzierbares Experiment zu entwickeln, das sich vollständig lokal ausführen und mit Python automatisieren lässt. Zusätzlich sollte geprüft werden, ob sich dieses Verhalten durch System-Prompts gezielt beeinflussen lässt.

2. Forschungsfragen und Hypothesen

Meine zentrale Forschungsfrage lautet:

Wie zuverlässig erkennen Large Language Models unterbestimmte Nutzeranfragen, und in welchem Maße lässt sich ihr Klärungsverhalten durch System-Prompts beeinflussen?

Daraus wurden vier Teilfragen abgeleitet:

• RQ1: Wie häufig stellen LLMs bei unterbestimmten Anfragen selbstständig eine notwendige Klärungsfrage?

• RQ2: Verändert bereits ein allgemeiner Helpful-Assistant-System-Prompt dieses Verhalten?

• RQ3: Wie stark verbessert eine explizite Klärungsinstruktion das Klärungsverhalten?

• RQ4: Unterscheidet sich das Verhalten zwischen verschiedenen Arten von Unterbestimmtheit und Ambiguität?

Vor dem Hauptexperiment wurden folgende Hypothesen formuliert:

• H1: Ohne spezielle Klärungsinstruktion beantworten die Modelle einen Teil der unterbestimmten Anfragen direkt und ergänzen fehlende Informationen durch plausible Annahmen.

• H2: Ein expliziter Klärungs-Prompt erhöht die Zahl korrekt erkannter Klärungsfälle deutlich.

• H3: Strukturell fehlende Informationen, zum Beispiel ein fehlender Referent oder ein fehlendes Argument, werden zuverlässiger erkannt als lexikalische Mehrdeutigkeit.

• H4 (explorativ): Ein allgemeiner Helpful-Assistant-Prompt kann das Verhalten leicht verändern, sollte aber einen geringeren Effekt haben als die gezielte Klärungsinstruktion.

3. Methodik

3.1 Datensatz

Für das Experiment wurde mit Unterstützung von GPT-5.6 ein eigener kontrollierter Datensatz erstellt. Das Modell lieferte Vorschläge für mögliche Fragen und Minimalpaare, diese wurden vom Autor ausgewählt, überarbeitet, teilweise verändert und zum finalen Datensatz zusammengestellt. Der Datensatz enthält 50 Minimalpaare und damit insgesamt 100 Anfragen. Er enthält 50 Minimalpaare und damit insgesamt 100 Anfragen. Jedes Paar besteht aus einer unterbestimmten Version, bei der eine Rückfrage notwendig ist (Gold-Label CLARIFY), und einer vollständig spezifizierten Version, bei der direkt geantwortet werden kann (Gold-Label ANSWER). Dadurch lässt sich prüfen, ob ein Modell wirklich auf die fehlende Information reagiert und nicht nur generell besonders vorsichtig oder besonders antwortfreudig ist.

Kategorie	**Unterbestimmt**	**Spezifiziert**
Fehlender Referent	„Who directed it?“	„Who directed the film Inception?“
Fehlendes Argument	„Convert 5 to kilograms.“	„Convert 5 pounds to kilograms.“
Fehlender Vergleich	„Which is older?“	„Which is older, the Eiffel Tower or the Statue of Liberty?“
Lexikalische Mehrdeutigkeit	„Translate the English word “bat” into German using exactly one word.“	Kontextsatz mit eindeutigem Bedeutungs-Sinn
Fehlender Scope/Kontext	„What is the legal drinking age?“	„What is the minimum legal age to buy beer in a supermarket in Germany?“

Tabelle 1: Die fünf Kategorien des Testdatensatzes.

Jede Kategorie enthält zehn Paare. Der Datensatz ist damit ausgeglichen: 50 Anfragen erfordern eine Klärung und 50 Anfragen sollen direkt beantwortet werden. Die im Pilotversuch verwendeten Beispiele wurden nicht in den finalen Testdatensatz übernommen. Dadurch sollte vermieden werden, dass die spätere Prompt-Formulierung speziell auf bekannte Testfälle zugeschnitten ist.

3.2 Modelle und technische Umgebung

Getestet wurden Gemma 4 12B und Qwen 3.8 27B. Beide Modelle wurden als Q4_K_M-Quantisierung lokal in LM Studio ausgeführt. Die Berechnung erfolgte auf einem PC mit einer GeForce RTX 5060 mit 16 GB VRAM und 32 GB Arbeitsspeicher. Die Anfragen wurden automatisiert über die lokale HTTP-API von LM Studio aus Python gesendet. Damit blieben alle Daten lokal und die Generierungsparameter konnten für beide Modelle identisch gesetzt werden.

Parameter	**Einstellung**
Reasoning / Thinking	ausgeschaltet
Temperature	0
Kontextlänge	8192 Tokens
Maximale Ausgabe	300 Tokens
Speicherung durch LM Studio	deaktiviert (store = false)
Quantisierung	Q4_K_M

Tabelle 2: Einheitliche Generierungsparameter im Hauptexperiment.

Die Temperature wurde auf 0 gesetzt, damit derselbe Prompt möglichst deterministisch verarbeitet wird. Das Experiment untersucht also primär das Klärungsverhalten unter festen Bedingungen und nicht die Schwankung zwischen mehreren zufälligen Generationen.

3.3 Drei Prompt-Bedingungen

Jede der 100 Anfragen wurde mit beiden Modellen unter drei Bedingungen getestet. Dadurch entstanden 2 Modelle x 3 Bedingungen x 100 Anfragen = 600 Modellantworten.

• No system: Es wurde kein eigener system_prompt an die API übergeben. Das normale Instruction-/Chat-Template des Modells blieb selbstverständlich aktiv.

• Helpful-Baseline: „You are a helpful assistant. Respond naturally and helpfully to the user's request."

• Clarification-aware: Eine gezielte System-Instruktion fordert das Modell auf, bei fehlender wesentlicher Information nachzufragen, keine wesentlichen Angaben selbst anzunehmen und bei bereits ausreichender Information direkt zu antworten.

Der Klärungs-Prompt wurde zunächst in einem kleinen Pilotversuch entwickelt. Eine zu schwache Formulierung änderte das Verhalten kaum. Eine zu strenge Formulierung führte teilweise zu unnötigen Rückfragen. Die finale Version versucht deshalb ausdrücklich,

notwendige Klärungen von überflüssigen Rückfragen zu unterscheiden. Nach dem Pilotversuch wurde diese Version nicht mehr verändert.

3.4 Auswertung der Antworten

Für die Auswertung wurden die 600 Antworten in vier Verhaltenskategorien eingeordnet:

• CLARIFY: Das Modell fragt ausdrücklich nach der fehlenden Information, bevor es eine eindeutige Antwort gibt.

• ANSWER: Das Modell beantwortet die Anfrage direkt oder entscheidet sich selbst für eine Interpretation.

• MIXED: Das Modell gibt bereits eine konkrete Antwort beziehungsweise Interpretation, bittet aber gleichzeitig noch um Klärung.

• OTHER: Das Modell erkennt zwar, dass Informationen fehlen, stellt aber keine konkrete Klärungsfrage und gibt auch keine eindeutige Antwort.

Für die Hauptauswertung wurde eine strenge binäre Bewertung verwendet. Bei unterbestimmten Anfragen gilt nur CLARIFY als Erfolg. Bei vollständig spezifizierten Anfragen gilt ANSWER als Erfolg. Dadurch wird klar geprüft, ob das Modell die richtige kommunikative Handlung auswählt.

Die wichtigsten Kennzahlen sind Accuracy, Precision, Recall und F1. Accuracy beschreibt den Anteil aller korrekt behandelten Anfragen. Der Recall für CLARIFY ist für dieses Projekt besonders wichtig, er zeigt, wie viele der tatsächlich klärungsbedürftigen Anfragen vom Modell auch wirklich als solche erkannt wurden. Precision zeigt dagegen, wie oft eine gestellte Klärungsfrage tatsächlich notwendig war. F1 verbindet Precision und Recall in einer gemeinsamen Kennzahl.

3.5 Statistischer Vergleich mit dem McNemar-Test

Da dieselben 100 Anfragen unter mehreren Prompt-Bedingungen getestet wurden, sind die Ergebnisse gepaart. Für den statistischen Vergleich wurde deshalb der exakte McNemar-Test verwendet. Der Test betrachtet vor allem die Fälle, in denen sich die beiden Bedingungen unterscheiden: wie oft war Bedingung A richtig und Bedingung B falsch, und wie oft war es umgekehrt? Wenn fast alle Änderungen nur in eine Richtung gehen, spricht das dafür, dass der

Unterschied nicht nur zufällig entstanden ist. Als übliche Orientierung wurde $p < 0{,}05$ verwendet. Die Tests sind hier als ergänzende, explorative Statistik zu verstehen.

4. Ergebnisse

4.1 Gesamtergebnisse

Modell	Bedingung	Accuracy	Precision	Recall	F1
Gemma 4 12B	Ohne System-Prompt	78 %	100 %	56 %	71.8 %
Gemma 4 12B	Helpful-Baseline	79 %	100 %	58 %	73.4 %
Gemma 4 12B	Klärungs-Prompt	90 %	100 %	80 %	88.9 %
Qwen3.8 27B	Ohne System-Prompt	73 %	100 %	46 %	63.0 %
Qwen3.8 27B	Helpful-Baseline	79 %	100 %	58 %	73.4 %
Qwen3.8 27B	Klärungs-Prompt	85 %	100 %	70 %	82.4 %

Tabelle 3: Hauptmetriken der strengen Auswertung.

Der deutlichste Effekt zeigt sich beim gezielten Klärungs-Prompt. Bei Gemma steigt die Accuracy von 78–79 % auf 90 %. Gleichzeitig steigt der Recall für notwendige Klärungen von 56–58 % auf 80 %. Bei Qwen steigt die Accuracy von 73 % ohne System-Prompt beziehungsweise 79 % in der Helpful-Baseline auf 85 % mit Klärungs-Prompt. Der Recall erhöht sich von 46–58 % auf 70 %.

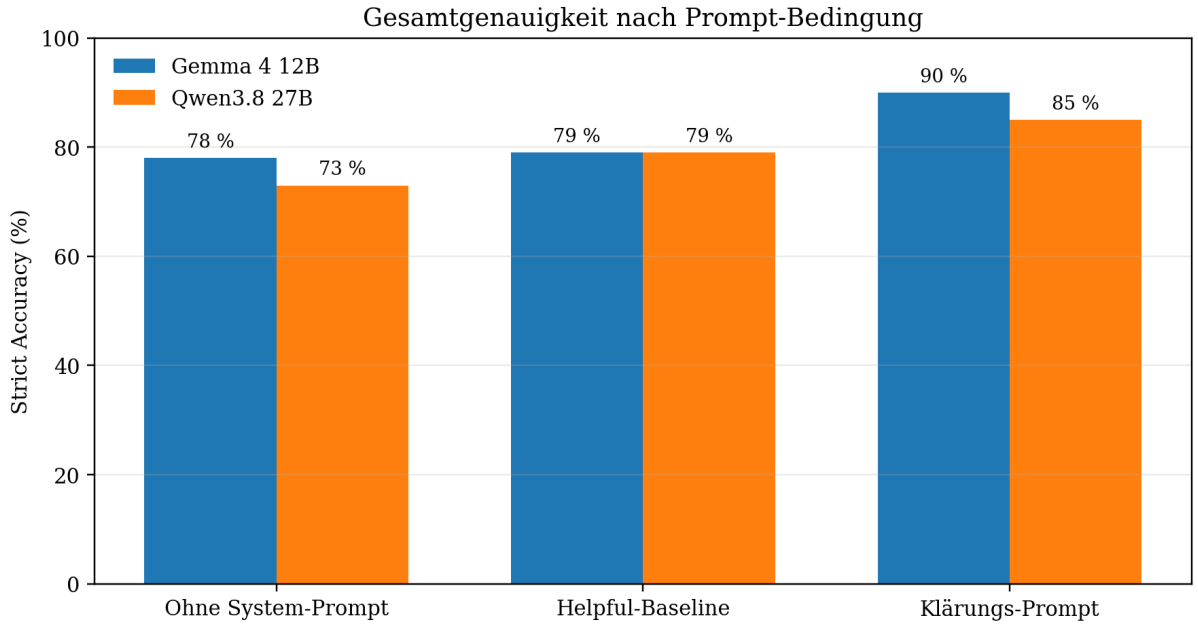


Abbildung 1: Strict Accuracy der beiden Modelle unter den drei Prompt-Bedingungen.

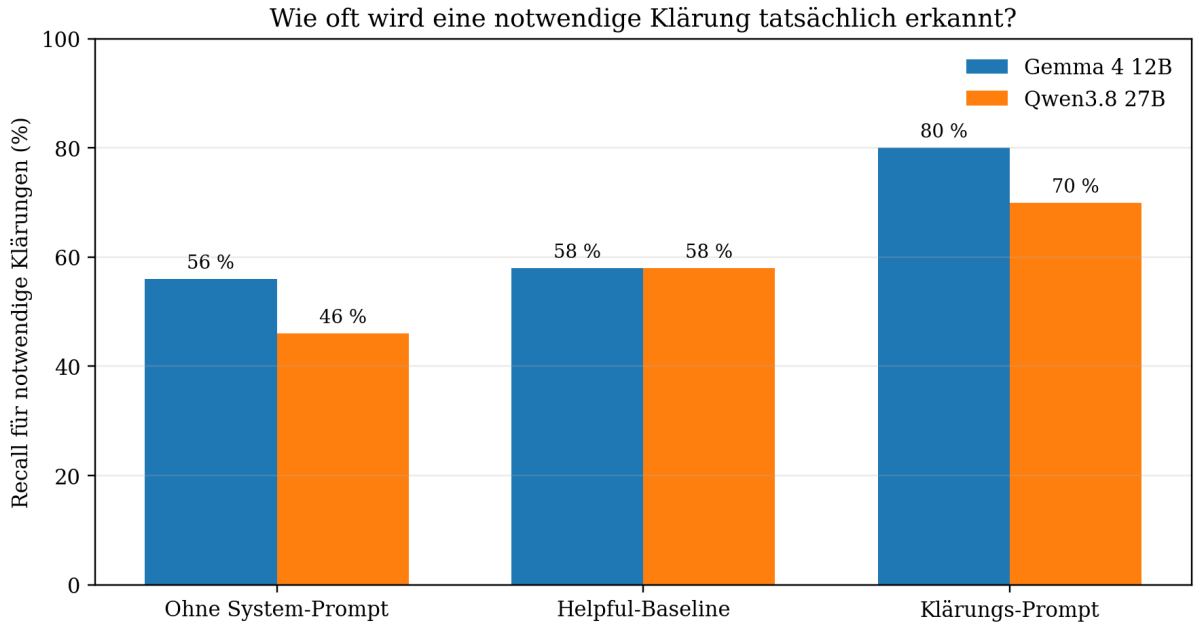


Abbildung 2: Recall für tatsächlich notwendige Klärungsfragen.

4.2 Wirkung der Prompt-Bedingungen

Der Vergleich zwischen No system und Helpful-Baseline zeigt, dass ein allgemeiner „hilfreicher Assistent“-Prompt allein nur einen kleinen Effekt hat. Bei Gemma verändert sich die Accuracy praktisch nicht (78 % gegenüber 79 %). Bei Qwen ist der Anstieg von 73 % auf 79 % etwas größer, der gepaarte McNemar-Test liefert dafür jedoch $p = 0{,}109$ und damit in diesem Datensatz keinen klaren statistischen Nachweis.

Deutlich anders sieht es beim Klärungs-Prompt aus. Für Gemma verbessert sich die Helpful-Baseline von 79 % auf 90 %. Dabei wurden elf zuvor falsch behandelte Anfragen korrekt und keine zuvor korrekte Anfrage falsch; der exakte McNemar-Test ergibt $p \approx 0{,}001$. Bei Qwen verbessert sich die Accuracy von 79 % auf 85 %, mit sechs Verbesserungen und keinen Verschlechterungen; hier ergibt sich $p = 0{,}031$. Auch der Vergleich direkt gegen No system fällt für beide Modelle klar zugunsten des Klärungs-Prompts aus (Gemma $p < 0{,}001$; Qwen $p \approx 0{,}002$).

Bemerkenswert ist außerdem die Precision von 100 % in allen Bedingungen. Im Datensatz gab es bei den vollständig spezifizierten Anfragen keinen Fall, in dem ein Modell unnötig eine Klärungsfrage stellte. Insgesamt wurden 300 solcher klaren Modellantworten erzeugt (50 klare

Anfragen × 2 Modelle × 3 Bedingungen), ohne einen False Positive. Der Klärungs-Prompt erhöhte in diesem Experiment also vor allem die Sensitivität für fehlende Informationen, ohne gleichzeitig zu messbarem Over-Clarification zu führen.

4.3 Unterschiede zwischen den Ambiguitätstypen

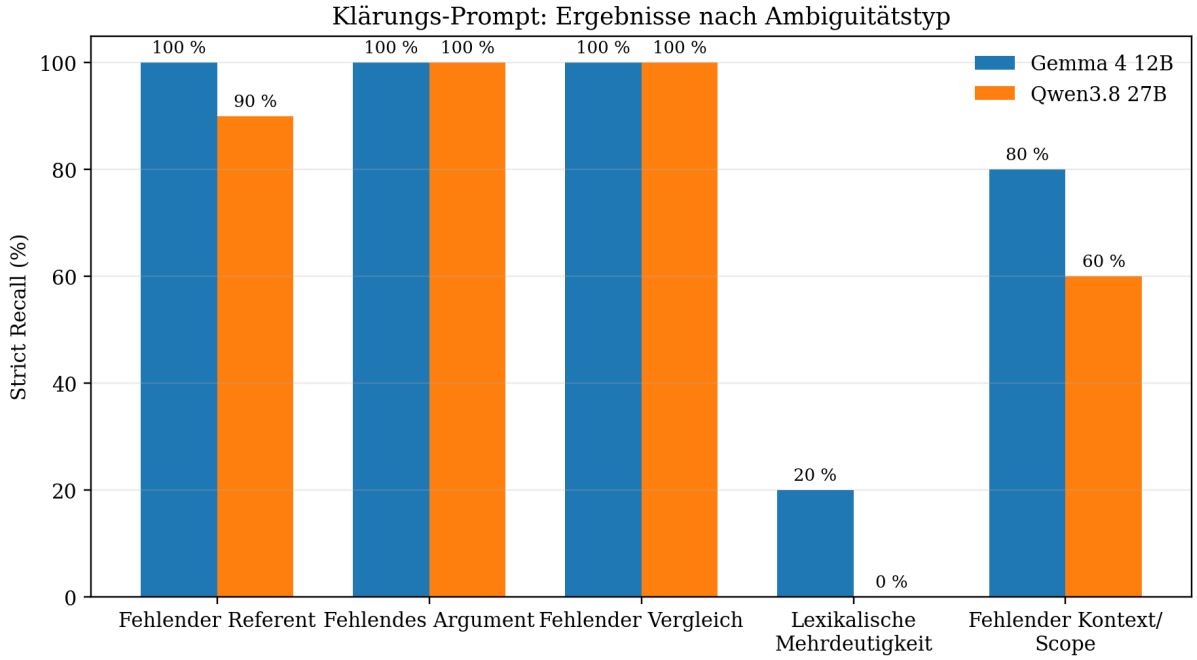


Abbildung 3: Strict Recall nach Ambiguitätstyp in der Clarification-aware-Bedingung.

Die Kategorien unterscheiden sich stark. Fehlende Vergleichsobjekte werden von beiden Modellen praktisch zuverlässig erkannt. Auch fehlende Referenten und fehlende numerische beziehungsweise textuelle Argumente funktionieren mit dem Klärungs-Prompt sehr gut. Schwieriger ist fehlender Scope, etwa eine nicht genannte Rechtsordnung oder ein nicht genanntes Land. Hier erreicht Gemma 80 % und Qwen 60 % Recall.

Am auffälligsten ist die lexikalische Mehrdeutigkeit. Bei Fragen wie „Translate the English word ‘bat’ into German using exactly one word.“ wählen die Modelle meist einfach die wahrscheinlichste Bedeutung, anstatt nach dem gemeinten Sinn zu fragen. Qwen erreicht in dieser Kategorie sogar mit Klärungs-Prompt 0 % Strict Recall, Gemma erreicht 20 %. Das spricht dafür, dass die Modelle eine offen fehlende Variable leichter als Unsicherheitsquelle erkennen als mehrere konkurrierende Bedeutungen eines vorhandenen Wortes.

5. Diskussion

Die Ergebnisse stützen die zentrale Annahme des Projekts. Das Klärungsverhalten von LLMs ist nicht fest vorgegeben, sondern lässt sich durch eine gezielte System-Instruktion deutlich verändern. Entscheidend ist dabei nicht einfach die Existenz eines System-Prompts. Der generische Helpful-Prompt verändert das Verhalten nur gering. Erst die explizite Regel, wesentliche fehlende Information nicht selbst anzunehmen und bei Bedarf nachzufragen, führt zu einem klaren Anstieg des Klärungs-Recalls.

Gleichzeitig zeigt das Experiment, dass „Unsicherheit erkennen“ kein einheitliches Problem ist. Wenn eine Anfrage grammatisch oder strukturell offensichtlich unvollständig ist, fällt die Klärungsentscheidung vergleichsweise leicht. Bei lexikalischer Mehrdeutigkeit ist die Situation anders: Das Modell besitzt eine dominante oder sehr wahrscheinliche Interpretation und behandelt diese offenbar häufig wie einen ausreichenden Kontext. Für die Praxis bedeutet das, dass ein einfaches Prompting zwar helfen kann, aber semantische Mehrdeutigkeit nicht automatisch löst.

Interessant ist auch der Vergleich der beiden Modelle. Das größere Qwen-Modell ist in diesem Experiment nicht grundsätzlich besser als Gemma. In der Helpful-Baseline liegen beide sogar bei denselben 79 % Accuracy und 58 % Recall. Mit Klärungs-Prompt erreicht Gemma 90 % Accuracy, Qwen 85 %. Daraus sollte jedoch nicht geschlossen werden, dass Gemma allgemein das bessere Modell ist. Das Experiment misst nur eine eng definierte kommunikative Fähigkeit unter einem kleinen, kontrollierten Datensatz.

6. Limitationen

Das Experiment ist bewusst klein und kontrolliert, deshalb sind die Ergebnisse nicht ohne Weiteres auf reale Dialoge übertragbar. Besonders wichtig sind folgende Einschränkungen:

• Der Datensatz wurde mit Unterstützung von GPT-5.6 Sol entwickelt und umfasst nur 50 Minimalpaare. Die Vorschläge des Modells wurden zwar vom Autor ausgewählt und überarbeitet, dennoch können sowohl Entscheidungen des Autors als auch die KI-gestützte Ideengenerierung die Auswahl und Formulierung der Testfälle beeinflusst haben.

• Es wurden nur zwei Modelle getestet. Außerdem unterscheiden sie sich in Größe und Architektur

• Die Modelle liefen quantisiert (Q4_K_M). Quantisierung kann das Verhalten leicht verändern.

• Temperature = 0 und nur eine Generation pro Prompt erhöhen die Reproduzierbarkeit, erlauben aber keine Aussage darüber, wie stabil dieselbe Entscheidung bei stochastischer Generierung wäre.

• Die 600 Antworten wurden anhand eines festen Codebooks von GPT-5.6 Sol im Thinking-Modus klassifiziert. Dadurch war eine konsistente Auswertung eines großen Antwortbestands möglich, gleichzeitig kann ein automatischer Evaluator eigene Bewertungsfehler oder systematische Biases einbringen. Eine unabhängige menschliche Zweitannotation und damit auch ein Inter-Annotator-Maß wurden nicht erhoben.

• Die lexikalischen Beispiele sind bewusst so formuliert, dass genau ein deutsches Wort verlangt wird. Das macht die Ambiguität messbar, ist aber etwas künstlicher als viele reale Gesprächssituationen.

• „Ohne System-Prompt“ bedeutet nur, dass kein eigener system_prompt mitgesendet wurde. Die jeweiligen Instruction-/Chat-Templates der Modelle blieben aktiv.

• Einige sehr ausführliche Antworten erreichten das feste Limit von 300 Output-Tokens. Die Einstellung wurde nach Beginn des Hauptexperiments nicht verändert, um die Vergleichbarkeit zu erhalten.

7. Fazit

Das Projekt zeigt, dass LLMs notwendige Klärungsfragen teilweise selbstständig erkennen, dabei aber stark von der Art der Unterbestimmtheit abhängen. Ein allgemeiner Helpful-Assistant-Prompt verändert das Verhalten nur wenig. Eine gezielte Klärungsinstruktion verbessert dagegen beide Modelle deutlich: Gemma erreicht 90 % und Qwen 85 % Strict Accuracy. Der größte Gewinn entsteht dadurch, dass zuvor übersehene Klärungsfälle häufiger erkannt werden.

Die Hypothesen H1 bis H3 werden damit im Rahmen dieses Datensatzes unterstützt. Besonders deutlich bestätigt sich H3: strukturell fehlende Information wird wesentlich zuverlässiger erkannt

als lexikalische Mehrdeutigkeit. Die explorative H4 wird nur teilweise unterstützt, weil der allgemeine Helpful-Prompt zwar bei Qwen einen kleinen numerischen Vorteil zeigt, dieser Effekt aber deutlich schwächer ist als der des gezielten Klärungs-Prompts.

Als nächster Schritt wäre es sinnvoll, den Datensatz zu vergrößern, weitere Modelle einzubeziehen und mehrstufige Dialoge zu testen. Dann könnte nicht nur untersucht werden, ob ein Modell eine Klärungsfrage stellt, sondern auch, ob die Frage tatsächlich die richtige fehlende Information erfragt und ob die anschließende Antwort nach der Klärung besser wird.

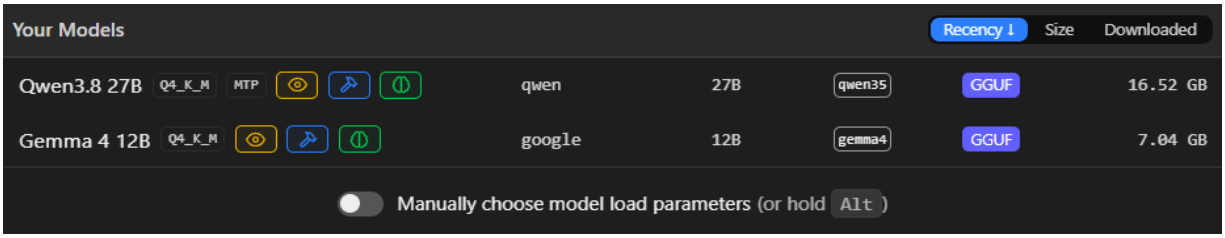
Anhang A: Finaler Klärungs-Prompt

> *You are a helpful assistant. Ask a clarification question only when essential information is missing and different plausible values for that missing information would lead to materially different answers. Do not assume missing essential information. However, do not ask for additional preferences, context, or details that are not necessary to complete the request. If all information required to perform the requested task is already provided, answer directly. When clarification is necessary, your response must consist of one concise clarification question and no tentative answer.*

Anhang B: Reproduzierbarkeit

Die Experimente wurden mit separaten Python-Skripten für Gemma und Qwen durchgeführt, da die Modelle wegen des Speicherbedarfs nacheinander in LM Studio geladen wurden. Jeder Modelllauf speicherte die Antworten nach jeder Anfrage direkt in eine CSV-Datei und konnte nach einem Abbruch fortgesetzt werden. Die vollständige Auswertung umfasst 600 Antworten. Bei der Entwicklung des Datensatzes und bei der späteren Verhaltensannotation wurde GPT-5.6 Sol unterstützend eingesetzt. Die getesteten Modelle Gemma und Qwen wurden nicht zur Bewertung ihrer eigenen Antworten verwendet. Zum Projekt gehören außerdem der Datensatz mit 50 Minimalpaaren sowie die zusammengeführte Ergebnisdatei mit den Verhaltenslabels.

Anhang C: LM Studio Modelle



Anhang D: Pilotverstuch (VS Code)

D: > llm_clarification_project > pilot_full.py > ...

```python
import requests
import csv
import time

URL = "http://127.0.0.1:1234/api/v1/chat"
MODEL = "google/gemma-4-12b"

BASELINE_PROMPT = (
    "You are a helpful assistant. "
    "Respond naturally and helpfully to the user's request."
)

CLARIFICATION_PROMPT = (
    "You are a helpful assistant. "
    "Ask a clarification question only when essential information is missing "
    "and different plausible values for that missing information would lead "
    "to materially different answers. "
    "Do not assume missing essential information. "
    "However, do not ask for additional preferences, context, or details "
    "that are not necessary to complete the request. "
    "If all information required to perform the requested task is already provided, "
    "answer directly. "
    "When clarification is necessary, your response must consist of one concise "
    "clarification question and no tentative answer."
)

QUERIES = [
    ("SCOPE01_A", "scope", "CLARIFY",
    "Who was the president in 1990?"),

    ("SCOPE01_B", "scope", "ANSWER",
    "Who was the president of the United States in 1990?"),

    ("ARG01_A", "argument", "CLARIFY",
    "Convert 100 to meters."),

    ("ARG01_B", "argument", "ANSWER",
    "Convert 100 feet to meters."),

    ("LEX01_A", "lexical", "CLARIFY"
```

Anhang E: Ausschnitt aus dem Testdatensatz

Query ID	Kategorie	Variante	GoldLabel	Anfrage
REF01_A	missing_referent	underspecified	CLARIFY	Where was she born?
REF01_B	missing_referent	specified	ANSWER	Where was Marie Curie born?
ARG01_A	missing_argument	underspecified	CLARIFY	Convert 72 to kilometers per hour.
ARG01_B	missing_argument	specified	ANSWER	Convert 72 miles per hour to kilometers per hour.
COMP01_A	missing_comparison	underspecified	CLARIFY	Which is farther north?
COMP01_B	missing_comparison	specified	ANSWER	Which is farther north, Rome or New York City?
LEX01_A	lexical_ambiguity	underspecified	CLARIFY	Translate the English word “bat” into German using exactly one word.
LEX01_B	lexical_ambiguity	specified	ANSWER	In “The bat flew out of the cave”, translate “bat” into German using exactly one word.
SCOPE01_A	missing_scope	underspecified	CLARIFY	What is the legal drinking age?
SCOPE01_B	missing_scope	specified	ANSWER	What is the minimum legal age to buy beer in a supermarket in Germany?